

Vademecum SMIQQDA

Ce document est soumis à la **licence CC BY-NC-ND 4.0**.

Citer ce document : Tiago JOSEPH. 2025. *Vademecum SMIQQDA (Social Media Interface for Quantitative and Qualitative Data Analysis)*. Version 1.0. SMIQQDA is available here: Zenodo, <https://doi.org/10.5281/zenodo.15642544>.

Citer le logiciel SMIQQDA : Tiago Joseph, Michaël Stappers, Gent University. 2025. *SMIQQDA, Social Media Interface for Quantitative and Qualitative Data Analysis*. Version 1.0. Zenodo, <https://doi.org/10.5281/zenodo.15642544>.

Synthèse des commandes fréquentes

- Lancer SMIQQDA : `python -m flask --app flaskr run`
- Afficher SMIQQDA : <http://localhost:5000/>
- Fermer SMIQQDA : `Ctrl + c`
- Importer corpus de comptes : `python -m flask --app flaskr import-excel-account-in-db`
- Importer corpus de posts : `python -m flask --app flaskr import-excel-post-in-db`
- Importer corpus OCR : `python -m flask --app flaskr import-excel-ocr-in-db`

Table des matières

Synthèse des commandes fréquentes.....	1
Légende	2
Etape 0 (étape unique) : préalables	2
Etape 1 (étape unique) : initialiser & réinitialiser SMIQQDA	3
Etape 2 : (ré)importer des données dans SMIQQDA.....	3
1. Importer un corpus de profils.....	3
2. Importer un corpus de publications	6
3. Importer un corpus d'OCR.....	8
4. Importer des annotations de TXM au format .xml	9
5. Vérifier les données de la base de données SMIQQDA.....	10
Etape 3 : lancer et fermer SMIQQDA.....	10
Etape 4 : utiliser les fonctionnalités de SMIQQDA	10
1. Sélectionner une interface	10
2. Visualiser et naviguer entre les profils	11
3. Visualiser et naviguer entre les publications	11
4. Annoter les profils	12
5. Annoter les publications.....	13
6. Exporter des corpus de profils et de publications	13
7. Sauvegarder, partager & restaurer la base de données	15
Fonctionnalités futures.....	15

Légende

- **En vert gras** : nom de dossier
- **En vert sans gras** : nom de fichier
- **En mauve** : nom de colonnes Excel
- **En bleu** : ligne de commande
- **En rouge** : ligne de commande sensible

Etape 0 (étape unique) : préalables

1. Pour utiliser SMIQQDA, il est nécessaire de télécharger Python ([Python 3.11.6](#)). Si l'installation de pandas ne fonctionne pas avec la version 32bits, privilégiez la version 64bits.

2. Téléchargez et dézippez le logiciel SMIQQDA sur Zenodo:

<https://doi.org/10.5281/zenodo.15642544> ou sur Github:

<https://github.com/SMIQQDA/SMIQQDA.git>

3. Retirez ce dossier de toute synchronisation (OneDrive, etc.) pour assurer un bon fonctionnement.

4. Il faut maintenant télécharger les briques logicielles nécessaires à l'utilisation de SMIQQDA :

- Flask==2.2.3 (<https://pypi.org/project/Flask/2.2.3/>) [serveur web qui fait tourner l'application]
- pandas==2.2.2 (<https://pypi.org/project/pandas/2.2.2/>) [permet de manipuler des fichiers Excel]
- XlsxWriter==3.1.4 (<https://pypi.org/project/XlsxWriter/3.1.4/>) [permet de créer des fichiers Excel]

Pour ce faire, ouvrez l'invite de commande/power shell en maintenant shift et le clic droit de votre souris sur le dossier **src** (pour « source » ou « code source », présent dans SMIQQDA). L'invite de commande remonte à la racine de l'ordinateur, manipulez-la avec précaution. Pour fermer l'invite de commande, il suffit de cliquer sur le bouton X en haut à droite.

Dans l'invite de commande, lancer les commandes suivantes (ensemble ou l'une après l'autre) :

```
python -m pip install Flask
python -m pip install pandas
python -m pip install XlsxWriter
python -m pip install openpyxl
```

Vous pouvez laisser l'invite de commande ouverte pour les prochaines étapes.

5. Bugs fréquents & solutions :

- « The term 'pip' is not recognized » : il faut installer Python.
- « The term 'flask' is not recognized as a name of a cmdlet, ... » : il faut installer Python.

6. Si vous souhaitez utiliser SMIQQDA pour différents projets de recherche, il suffit de dupliquer le logiciel (un dossier SMIQQDA par projet) ; il n'est pas nécessaire de travailler au sein du même dossier et de remplacer la base de données systématiquement.

Etape 1 (étape unique) : initialiser & réinitialiser SMIQQDA

1. Pour pouvoir utiliser SMIQQDA, la première étape est d'initialiser une base de données qui va accueillir l'ensemble des données textuelles (le corpus) et des annotations (les analyses). Cette étape ne doit et ne peut être réalisée qu'une seule fois pour chaque corpus : en effet, elle entraîne la création d'une nouvelle base de données qui écrase la base de données précédente contenue dans ce dossier SMIQQDA (si elle existe).

Pour initialiser la base de données, lancez la commande suivante dans l'invite de commande/power shell (si elle est fermée, vous pouvez l'ouvrir en maintenant shift et le clic droit de votre souris sur le dossier **src**) :

```
python -m flask --app flaskr init-db
```

Vous pouvez laisser l'invite de commande ouverte pour les prochaines étapes.

2. Si vous souhaitez réinitialiser votre base de données, il est nécessaire de supprimer le fichier **flask.sqlite** (ou de l'archiver en le renommant), qui se trouve dans le dossier **instance** (src > instance). Il suffit ensuite de relancer la commande de réinitialisation.

Etape 2 : (ré)importer des données dans SMIQQDA

Une fois la base de données initialisée (cfr. étape 1), vous pouvez y importer des données. Ces données ont généralement été collectées via un outil de scrapping. Si votre outil de scrapping ne fournit pas directement les données visuelles mais vous fournit néanmoins un lien URL (généralement temporaire) vers celles-ci, nous vous conseillons d'utiliser nos scripts de collecte **download_profilepictures.py** (pour les photos de profil) et **download_postpictures.py** (pour les images des publications) disponibles dans le dossier de **documentation** de SMIQQDA. Il suffit d'adapter le nom du fichier et le chemin vers le fichier .json contenant les liens URL.

Nous conseillons vivement de respecter scrupuleusement ces consignes pour assurer le bon fonctionnement du display.

1. Importer un corpus de profils

L'import d'un corpus de profils est une étape obligatoire pour l'import de corpus de publications : SMIQQDA n'importe que les publications dont les profils ont déjà été importés. Cette contrainte permet de gérer le bruit des données numériques en laissant de côté des publications issues de comptes qui n'intéressent pas les chercheuses.

Si vous n'avez pas de corpus de profils, il est toujours possible d'utiliser SMIQQDA. Il suffit de créer un fichier Excel contenant les données requises (cfr. ci-dessous) ; cela ne prend que quelques instants.

a. Pour commencer, il faut importer les données visuelles dans SMIQQDA :

Si vous avez collecté des photos de profil, copiez et collez ces photos dans le dossier **profilepictures** (src\flaskr\static\insta\profilepictures). Les images restent stockées sur l'ordinateur et ne sont pas importées dans la base de données.

Ces photos de profil doivent respecter le format .jpg et les conditions de nommage suivantes : « **account_pic.jpg** » où account doit être remplacé par le nom de chaque compte. Pour plus de facilité, nous vous conseillons d'utiliser notre script de collecte des images (cfr. introduction de l'étape 2).

Si vous ne possédez pas les photos de profil (par exemple, si vous n'avez pas de corpus de profils), ne faites rien. Ce n'est pas un problème : il est possible d'utiliser SMIQQDA sans posséder les photos de profil. Cela permet également d'utiliser SMIQQDA si la collecte des images est incomplète ou inexistante.

Lors de l'import, les doublons sont supprimés automatiquement.

b. Ensuite, il faut préparer le fichier Excel contenant les profils :

Suite à la collecte des données, vous disposez d'un fichier Excel qui contient les profils (une ligne par profil) et leurs métadonnées (une colonne par métadonnée). Il est nécessaire de préparer ce fichier selon les conventions de SMIQQDA :

- **Nom du fichier** : le fichier Excel doit s'intituler **accounts.xlsx**. Si vous souhaitez changer le nom du fichier d'import, vous pouvez modifier la variable dans la ligne **PATH_EXCEL** dans le fichier **db.py** dans le dossier **db** (src > flaskr > db).
- **Emplacement du fichier** : le fichier doit être placé dans le dossier **account** (flaskr > import > excel > account).
- **Nom des colonnes** : les espaces et les caractères spéciaux (/ ; . ' -) ne sont pas acceptés dans les noms de colonnes.
- **Contenu des cellules** : il n'y a aucune restriction sur le contenu des cellules.
- **Colonnes obligatoires** : le fichier doit nécessairement contenir les colonnes suivantes :
 - ✓ **account** [nom du compte ; la colonne ne peut pas être vide, aucune répétition entre différentes cellules (identifiant unique)]
 - ✓ **idAccount** [identifiant unique du compte ; la colonne ne peut pas être vide : elle doit être remplie par un ou plusieurs chiffres, sans répétition entre différentes cellules (identifiant unique)]
 - ✓ **biography** [biographie du compte ; la colonne peut être vide]
 - ✓ **freeAnnotationAccount** [annotations libres ; la colonne peut être vide]
 - ✓ **fullName** [sous-nom du compte ; la colonne peut être vide]
 - ✓ **externalUrl** [lien URL présent dans la biographie ; la colonne peut être vide]
 - ✓ **postsCount** [nombre de posts du compte ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]
 - ✓ **followersCount** [nombre d'abonné.e.s ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]
 - ✓ **followsCount** [nombre d'abonnements ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]

- **Colonnes facultatives fonctionnelles** : il est possible d'ajouter des colonnes offrant des fonctionnalités supplémentaires. Pour éviter les bugs, il est conseillé d'inclure ces colonnes dans tous les cas (toutes peuvent être vides) :
 - ✓ **postsAsked** [nombre de posts demandés pour chaque compte à l'outil de scraping ; la colonne attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA ; si la colonne est absente, la valeur par défaut est de 500 publications par compte]
 - ✓ **postsReallyCollected** [nombre de publications du compte réellement importées dans la base de données, sans les doublons ; si la colonne existe, elle ne peut pas être vide – la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA ; colonne automatiquement créée et calculée par SMIQQDA lors de l'export]
 - ✓ **imagesLocalPathAccount** [chemin des photos de profil, pour l'édition dans TXM ; colonne automatiquement créée par SMIQQDA lors de l'export]
 - ✓ **postsMissing** [nombre de posts non collectés (postsAsked - postsReallyCollected), utile pour évaluer la qualité de la collecte ; si la colonne existe, la colonne ne peut pas être vide – la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA ; colonne automatiquement créée et calculée par SMIQQDA lors de l'export]
 - ✓ **catAccount_NomCatégorie** [catégories cliquables issues d'analyses de contenu préalables, utiles pour le filtrage et la création de sous-corpus ; vous pouvez transformer n'importe quelle colonne en catégorie en ajoutant le préfixe **catAccount_** devant le nom de la catégorie ; importées uniquement à l'import des profils ; cfr. étape 4.4]
 - ✓ **urlAccount** [url du profil, cliquable dans SMIQQDA]
 - ✓ **oldAccount** [autre nom d'un compte ayant changé de nom]
- **Colonnes facultatives dormantes** : vous pouvez laisser dans le fichier Excel n'importe quelle colonne supplémentaire. Ces colonnes seront importées et exportées depuis SMIQQDA, mais ne seront pas utiles et n'apparaîtront donc pas dans l'interface de navigation et d'annotation (cfr. étape 3).

c. Ensuite, il faut importer le fichier Excel dans SMIQQDA :

Dans l'invite de commande, lancez la commande :

```
python -m flask --app flaskr import-excel-account-in-db
```

d. Enfin, pour réimporter des données dans SMIQQDA :

Si vous enrichissez ou modifiez vos données en dehors de SMIQQDA et que vous souhaitez actualiser ces changements dans SMIQQDA, il est possible de le faire. Cela peut être intéressant si vous réalisez des analyses complémentaires dans d'autres logiciels ou si vous effectuez des modifications et des ajouts directement dans Excel.

Dans ce cas, il suffit d'importer à nouveau le fichier Excel des profils dans SMIQQDA. Les données de la base de données seront remplacées si et seulement si des données équivalentes sont présentes dans le fichier Excel. Cela signifie que vous pouvez importer un fichier partiel (ne contenant que certaines données, supplémentaires ou modifiées) – ce qui diminue considérablement le temps d'import des données. Dans ce cas, il est important de toujours conserver dans le fichier Excel les colonnes obligatoires, qui permettent d'associer les données au profil adéquat. Les colonnes (liste des métadonnées) ou les lignes (liste des profils) qui ne sont pas présentes dans le fichier Excel demeurent intactes dans la base de données (elles ne sont ni supprimées ni modifiées dans la base de données).

Nous vous conseillons également de conserver une copie de chaque fichier d'import **accounts** (changez le nom du fichier d'import précédent et évitez ainsi de l'écraser par le nouveau). N'oubliez pas également d'ajouter le préfixe `catAccount_` pour transformer des colonnes en catégories d'analyse utilisables dans SMIQQDA.

2. Importer un corpus de publications

Avant d'importer un corpus de publications, il est nécessaire d'importer un corpus de profils. Si vous n'avez pas de corpus de profils, il est toujours possible d'utiliser SMIQQDA (cfr. étape 2.1.).

Lors de l'import, les doublons sont supprimés automatiquement.

a. Pour commencer, il faut importer les données visuelles dans SMIQQDA :

Si vous avez collecté les images des publications, copiez et collez ces photos dans le dossier **comptes** (`src\flaskr\static\insta\comptes`). Ce dossier est constitué de sous-dossiers intitulés par le nom du compte. Les images restent stockées sur l'ordinateur et ne sont pas importées dans la base de données.

Chaque sous-dossier (un par compte) comprend l'ensemble des images des publications collectées. Ces images doivent respecter le format `.jpg` et les conditions de nommage suivantes : « `account_JJ-MM-AA_HH-MM-SS_Numéro_Total.jpg` », c'est-à-dire le nom du compte, suivi du timestamp (jour-mois-année_heure-minute-seconde) et des informations sur les images du post (numéro de l'image suivi du nombre total d'images du posts : par exemple "1_5" pour la première image d'un post en comptant 5) (exemple : `"rebeccakadagaug_01-04-21_09-23-05_1_5"`). Cela implique qu'il est nécessaire de disposer des métadonnées **account** et **timestamp** pour associer les données visuelles et les données textuelles. Pour plus de facilité, nous vous conseillons d'utiliser notre script de collecte des images (cfr. introduction de l'étape 2).

Si vous ne possédez pas toutes les images de toutes les publications, ce n'est pas un problème : il est possible d'utiliser SMIQQDA même si la collecte des images est incomplète.

b. Ensuite, il faut préparer le fichier Excel contenant les publications :

Suite à la collecte des données, vous disposez d'un fichier Excel qui contient les publications (une ligne par publication) et leurs métadonnées (une colonne par métadonnée). Il est nécessaire de préparer ce fichier selon les conventions de SMIQQDA :

- **Nom du fichier** : le fichier Excel doit s'intituler **post.xlsx**. Si vous souhaitez changer le nom du fichier d'import, vous pouvez modifier la variable dans la ligne `PATH_EXCEL` dans le fichier `db.py` dans le dossier **db** (`src > flaskr > db`).
- **Emplacement du fichier** : le fichier doit être placé dans le dossier **post** (`flaskr > import > excel > post`).
- **Nom des colonnes** : les espaces et les caractères spéciaux (`/ ; . ' -`) ne sont pas acceptés dans les noms de colonnes.
- **Contenu des cellules** : il n'y a aucune restriction sur le contenu des cellules.
- **Colonnes obligatoires** : le fichier doit nécessairement contenir les colonnes suivantes :
 - ✓ **account** [nom du compte, correspondant à celui du profil importé ; la colonne ne peut pas être vide, aucune répétition entre différentes cellules (identifiant unique)]
 - ✓ **fullName** [sous-nom du compte ; la colonne peut être vide]

- ✓ **idAccount** [identifiant unique du compte, correspondant à celui du profil importé ; la colonne ne peut pas être vide : elle doit être remplie par un ou plusieurs chiffres, sans répétition entre différentes cellules (identifiant unique)]
- ✓ **postId** [identifiant unique de la publication ; la colonne ne peut pas être vide : elle doit être remplie par un ou plusieurs chiffres, sans répétition entre différentes cellules (identifiant unique)]
- ✓ **freeAnnotationPost** [annotations libres ; la colonne peut être vide]
- ✓ **timestampApify** [timestamp fourni par votre outil de scraping, par exemple Apify, comprenant généralement des erreurs de décalage horaire/changement d'heures, au format « JJ-MM-AAAA HH:MM:SS » - pour obtenir ce format depuis un autre format de timestamp (contenant par exemple « oz »), convertissez votre fichier Excel en tableau de données ; la colonne ne peut pas être vide]
- ✓ **ocr** [résultat de l'OCR ; la colonne peut être vide]
- ✓ **numberImagesPost** [nombre d'images de la publication, que vous pouvez calculer manuellement à partir du nombre de liens URL fournis par l'outil de collecte ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]
- ✓ **caption** [légende de la publication ; la colonne peut être vide]
- ✓ **locationName** [identification d'un lieu par l'adresse du post ; la colonne peut être vide]
- ✓ **likesCount** [nombre de likes ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]
- ✓ **commentsCount** [nombre de commentaires ; la colonne ne peut pas être vide : elle attend un ou plusieurs chiffres - la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA]
- ✓ **urlPost** [url de la publication, cliquable dans SMIQQDA ; la colonne peut être vide]
- ✓ **type** [nature de la publication, généralement image ou vidéo ; la colonne peut être vide]
- **Colonnes facultatives fonctionnelles** : il est possible d'ajouter des colonnes offrant des fonctionnalités supplémentaires. Pour éviter les bugs, il est conseillé d'inclure ces colonnes dans tous les cas (toutes peuvent être vides) :
 - ✓ **ocrConfidenceCoef** [coefficient de confiance de l'OCR ; si la colonne existe, elle ne peut pas être vide : elle attend un ou plusieurs chiffres – la valeur n'a pas d'influence sur le fonctionnement de SMIQQDA ; si la colonne n'existe pas, elle est générée automatiquement et la valeur de base est de 0 – en attendant l'import du corpus d'OCR]
 - ✓ **oldAccount** [autre nom d'un compte ayant changé de nom ; la colonne est générée automatiquement à l'export]
 - ✓ **catPost_NomCatégorie** [catégories cliquables issues d'analyses de contenu préalables, utiles pour le filtrage et la création de sous-corpus ; vous pouvez transformer n'importe quelle colonne en catégorie en ajoutant le suffixe **catPost_** devant le nom de la catégorie ; importées uniquement à l'import des publications ; cfr. étape 4.5]
- **Colonnes facultatives dormantes** : vous pouvez laisser dans le fichier Excel n'importe quelle colonne supplémentaire. Ces colonnes seront importées et exportées depuis SMIQQDA, mais ne seront pas utiles et n'apparaîtront donc pas dans l'interface de navigation et d'annotation (cfr. étape 3).

- **Colonnes ignorées** : les colonnes `catAccount_` sont ignorées lors de l'import des publications. Pour les importer et les exporter (sans les transformer en catégories cliquables), modifier « `catAccount_` » en « `catAccount1_` » ; pour les transformer en catégories cliquables pour les publications, modifier « `catAccount_` » en « `catPost_catAccountNomCatégorie` ».
- **Ordre des posts** : l'ordre des posts de l'Excel sera également l'ordre d'affichage des posts (par compte) dans le display. Triez les posts (par date ou tout autre critère pertinent) avant l'import.

c. Ensuite, il faut importer le fichier Excel dans SMIQQDA :

Dans l'invite de commande, lancez la commande :

```
python -m flask --app flaskr import-excel-post-in-db
```

d. Enfin, pour réimporter des données dans SMIQQDA :

Si vous enrichissez ou modifiez vos données en dehors de SMIQQDA et que vous souhaitez actualisez ces changements dans SMIQQDA, il est possible de le faire. Voir l'étape 2.1.d. pour des conseils supplémentaires.

3. Importer un corpus d'OCR

L'import d'un corpus d'OCR, c'est-à-dire des résultats d'une OCR sur les images des publications, est facultatif. Il n'est pas nécessaire pour utiliser SMIQQDA.

Lors de l'import, les doublons sont supprimés automatiquement.

a. Pour commencer, il faut préparer le fichier Excel contenant les publications :

Suite à la réalisation d'un OCR sur les images des publications, vous disposez d'un fichier Excel qui contient les résultats de l'OCR (une ligne par publication) et leurs métadonnées (une colonne par métadonnée). Il est nécessaire de préparer ce fichier selon les conventions de SMIQQDA :

- **Nom du fichier** : le fichier Excel doit s'intituler `ocr.xlsx`. Si vous souhaitez changer le nom du fichier d'import, vous pouvez modifier la variable dans la ligne `PATH_EXCEL` dans le fichier `db.py` dans le dossier `db` (src > flaskr > db).
- **Emplacement du fichier** : le fichier doit être placé dans le dossier `ocr` (flaskr > import > excel > ocr).
- **Nom des colonnes** : les espaces et les caractères spéciaux (/ ; . ' -) ne sont pas acceptés dans les noms de colonnes.
- **Contenu des cellules** : il n'y a aucune restriction sur le contenu des cellules.
- **Colonnes obligatoires** : le fichier doit nécessairement contenir les colonnes suivantes :
 - ✓ `account` [nom du compte, correspondant à celui du profil/post importé ; la colonne ne peut pas être vide]
 - ✓ `timestampApify` [timestamp fourni par votre outil de scraping, correspondant à celui du post importé et comprenant généralement des erreurs de décalage horaire/changement d'heures, au format « JJ-MM-AAAA HH:MM:SS » - pour obtenir ce format depuis un autre format de timestamp, convertissez votre fichier Excel en tableau de données ; la colonne ne peut pas être vide]
 - ✓ `ocr` [résultat de l'OCR ; la colonne peut être vide]

- **Colonnes facultatives fonctionnelles** : il est possible d'ajouter des colonnes offrant des fonctionnalités supplémentaires. Pour éviter les bugs, il est conseillé d'inclure ces colonnes dans tous les cas (toutes peuvent être vides) :
✓ **ocrConfidenceCoef** [coefficient de fiabilité de l'OCR]
- **Colonnes facultatives dormantes** : vous pouvez laisser dans le fichier Excel n'importe quelle colonne supplémentaire. Ces colonnes seront importées et exportées depuis SMIQQDA, mais ne seront pas utiles et n'apparaîtront donc pas dans l'interface de navigation et d'annotation (cfr. étape 3).

c. Ensuite, il faut importer le fichier Excel dans SMIQQDA :

Dans l'invite de commande, lancez la commande :

```
python -m flask --app flaskr import-excel-ocr-in-db
```

d. Enfin, pour réimporter des données dans SMIQQDA :

Si vous enrichissez ou modifiez vos données en dehors de SMIQQDA et que vous souhaitez actualiser ces changements dans SMIQQDA, il est possible de le faire. Voir l'étape 2.1.d. pour des conseils supplémentaires.

4. Importer des annotations de TXM au format .xml

Si vous annotez votre corpus à l'aide du logiciel de textométrie TXM, vous devez exporter les annotations en format .xml. Ces annotations sont importables dans SMIQQDA, à condition que les métadonnées suivantes y soient associées :

- **Pour les profils** : **idAccount** (correspondant à un profil importé)
- **Pour les publications** : **postId** (correspondant à une publication importée)

a. Pour commencer, il faut adapter SMIQQDA aux balises d'annotation utilisées par le logiciel :

Conçu pour être compatible avec TXM, SMIQQDA reconnaît actuellement les balises <txm : nomCatégorie>. Chaque balise entraînera la création d'une catégorie spécifique. Il est donc possible d'importer des annotations à plusieurs reprises. Si des annotations ont été mises à jour dans le fichier .xml, elles seront actualisées dans SMIQQDA.

b. Ensuite, il faut placer le fichier .xml dans SMIQQDA :

- **Pour les profils** : placez le fichier intitulé **TXMAccount.xml** dans **account** (flaskr > import > txm > account).
- **Pour les publications** : placez le fichier intitulé **TXMPost.xml** dans **post** (flaskr > import > txm > post).

Si vous souhaitez changer le nom du fichier d'import, vous pouvez modifier la variable dans la ligne **PATH_TXM** dans le fichier **db.py** dans le dossier **db** (src > flaskr > db).

c. Ensuite, il faut importer le fichier .xml dans SMIQQDA :

Dans l'invite de commande, lancez la commande suivante pour les annotations de profils :

```
python -m flask --app flaskr import-txm-account-in-db
```

Dans l'invite de commande, lancez la commande suivante pour les annotations de publications :

```
python -m flask --app flaskr import-txm-post-in-db
```

5. Vérifier les données de la base de données SMIQQDA

En cas de bug, il est possible de vérifier le contenu et la structuration des données de SMIQQDA manuellement, grâce à l'outil **db Browser**.

Etape 3 : lancer et fermer SMIQQDA

1. Pour lancer SMIQQDA, lancez la commande suivante dans l'invite de commande (ouvrez l'invite de commande/power shell en maintenant **shift** et le **clic droit** de votre souris sur le dossier **src** présent dans SMIQQDA) :

```
python -m flask --app flaskr run
```

2. Entrez le lien suivant dans une page internet :

<http://localhost:5000/>

Vous venez d'ouvrir l'interface de navigation et d'annotation. Vous pouvez désormais naviguer dans votre corpus, l'annoter et l'exporter. Vous n'avez pas besoin d'une connexion internet pour utiliser SMIQQDA. Si vous souhaitez importer de nouvelles données dans SMIQQDA, il est nécessaire de le fermer au préalable.

3. Pour fermer SMIQQDA, lancez simultanément les touches suivantes dans l'invite de commande :

Ctrl + c

Vous pouvez ensuite fermer l'invite de commande et la page internet :

- Pour fermer l'invite de commande, il suffit de cliquer sur le bouton X en haut à droite. Attention : pour éviter les bugs, il est nécessaire de commencer par fermer SMIQQDA avant de fermer l'invite de commande. En effet, la fermeture de l'invite de commande entraîne la fermeture (non sécurisée) de SMIQQDA.
- Vous pouvez fermer la fenêtre internet en cliquant sur le bouton X en haut à droite. Si vous fermez cette fenêtre par inadvertance pendant l'utilisation de SMIQQDA, ce n'est pas grave ; il suffit de la rouvrir et vos données ont été sauvegardées. Si vous importez de nouvelles données dans SMIQQDA, vous pouvez garder cette page internet ouverte et simplement la réactualiser après avoir fermé SMIQQDA dans l'invite de commande, importé vos données et relancé SMIQQDA.

4. Bugs & solutions :

- Il est possible que l'affichage des données soit soumis à des latences ou des bugs. Dans ce cas, vous pouvez réactualiser la page internet. Si le problème n'est pas résolu, vous pouvez également entrer la commande **enter** dans l'invite de commande.

Etape 4 : utiliser les fonctionnalités de SMIQQDA

1. Sélectionner une interface

Lorsque vous lancez SMIQQDA, vous arrivez automatiquement sur l'interface des publications. Si vous descendez en bas de la page, vous pouvez sélectionner une des six interfaces du logiciel :

- **Post** : visualiser et annoter les publications ;
- **Account** : visualiser et annoter les profils ;
- **Edit category for accounts** : créer (et archiver) des catégories cliquables pour annoter les profils ;

- **Edit category for posts** : créer (et archiver) des catégories cliquables pour annoter les publications ;
- **Export post** : exporter des corpus de publications ;
- **Export account** : exporter des corpus de profils.

La suite du document explique en détails les fonctionnalités de chacune de ces interfaces.

2. Visualiser et naviguer entre les profils

En cliquant sur l'interface Account, vous pourrez visualiser les données des profils. Vous pouvez :

- Défiler d'un profil à l'autre avec les flèches gauche et droite ;
- Sélectionner un profil spécifique dans la liste (soit en la déroulant, soit en écrivant son nom dans la barre de recherche, puis en appuyant sur Go) ;
- Annoter les profils (via l'espace d'annotation libre et les catégories cliquables, cfr. étape 4.4) ;
- Sélectionner un ensemble de profils à l'aide du filtre. Vous pouvez sélectionner un ou plusieurs filtres (ils se cumulent comme un opérateur booléen « et » ; il n'est donc pas possible de sélectionner deux sous-catégories d'une même catégorie). Le nombre de profils filtrés est indiqué à droite du nom du compte, suivi du total des profils entre parenthèses.

3. Visualiser et naviguer entre les publications

En cliquant sur l'interface Post, vous pourrez visualiser les données des publications. Vous pouvez :

- Défiler en boucle entre les images d'une publication avec les flèches gauche et droite (le nombre d'images est indiqué) ;
- Défiler en boucle entre les publications d'un même compte avec les flèches haut et bas, ou en sélectionnant le numéro de la publication (le nombre de publications du compte est indiqué) ;
- Défiler en boucle entre les publications d'un même jour en cliquant sur le bouton *Switch date mode*.
 - ✓ Un bouton date apparaît : sélectionnez une date, et vous aurez accès à toutes les publications de tous les comptes publiées ce jour-là.
 - ✓ Pour défiler entre les images, utilisez les flèches gauche et droite.
 - ✓ Pour défiler d'une publication à l'autre, utilisez les flèches haut et bas (après la dernière publication, vous reviendrez en boucle sur la première publication).
 - ✓ Pour défiler d'un compte à l'autre, utilisez les boutons 1 et 2.
 - ✓ Pour passer à la date antérieure ou ultérieure, utilisez les flèches situées de part et d'autre de la date. **Attention** : si la date précédente ou suivante n'existe pas dans les données, un message d'erreur vous avertira. Il est alors nécessaire de remplir à nouveau une date disponible dans le bouton date (ou de faire défiler les dates avec les flèches, jusqu'à la disparition du message d'erreur), sans quoi les données ne s'affichent plus de manière adéquate.
 - ✓ Pour revenir au mode normal (affichage par compte), appuyez à nouveau sur le bouton *Switch date mode*.
- Défiler en boucle d'un compte à l'autre avec les chiffres 1 et 2 (le nombre de comptes est indiqué) ;
- Sélectionner les publications d'un profil spécifique dans la liste (soit en la déroulant, soit en écrivant son nom dans la barre de recherche, puis en appuyant sur Go) ;
- Annoter les publications (via l'espace d'annotation libre et les catégories cliquables, cfr. étape 4.5) ;
- Sélectionner un ensemble de publications à l'aide du filtre. Vous pouvez sélectionner un ou plusieurs filtres (ils se cumulent comme un opérateur booléen « et » ; il n'est donc pas possible de sélectionner deux sous-catégories d'une même catégorie), qu'ils s'appliquent aux profils

(filter account) ou aux publications (filter post). Le nombre de profils et de publications filtrées est indiqué à droite du nom du compte, suivi du total des profils et des publications entre parenthèses.

4. Annoter les profils

Vous pouvez annoter les profils de deux façons :

- En écrivant dans l'espace d'annotation libre. Ces annotations se sauvegardent automatiquement, dès que vous cliquez en dehors de l'encadré d'annotation.
- En utilisant des catégories cliquables. Ces catégories peuvent avoir été créées lors de l'import (cfr. étapes 2.1), ou peuvent être créées dans SMIQQA, dans l'interface **Edit category for accounts**.

Pour créer des catégories dans l'interface **Edit category for accounts**, entrez le nom de la catégorie et cliquez sur Add category. Vous pourrez ensuite créer des sous-catégories en cliquant sur Add sub-category. Catégories et sous-catégories sont classées par ordre alphabétique, et non par ordre d'entrée. Il est nécessaire de respecter les règles de nommage suivantes :

- Les majuscules et les chiffres sont acceptés. Nous conseillons de numérotter les catégories et sous-catégories (00, 01, etc.) si l'ordre d'entrée vous importe.
- Les signes diacritiques (apostrophes, cédilles, accents, etc) ne sont pas acceptés, ainsi que les espaces entre les mots (privilégiez des underscore).
- Certaines valeurs sont à éviter, notamment les nombres seuls ainsi que les valeurs génériques : « true/false » ; "vraie/faux" ; « oui/non » ; etc.

Pour créer des catégories lors de l'import, ajoutez le préfixe catAccount_ suivi du nom de la colonne dans le fichier Excel (les catégories des profils ne peuvent être importées que lors de l'import de profils). Nous vous conseillons de numérotter les catégories (après le symbole underscore) et d'éviter transformer en catégories des colonnes dont les cellules contiennent des valeurs uniques (bruit). Il est possible d'importer des annotations d'une catégorie déjà créée dans le display, il est alors impératif de respecter à l'identique le nom de la catégorie et des sous catégories. Veillez à ne pas laisser d'espace à la fin.

Pour supprimer une catégorie ou une sous-catégorie, cliquer sur Delete. Si une catégorie est supprimée, toutes ses variables et les annotations réalisées sont également supprimées. Lors de la suppression, une double confirmation est demandée pour éviter les fausses manipulations.

Pour archiver une catégorie ou une sous-catégorie, cliquez sur Archive. La (sous-)catégorie ne s'affichera plus dans l'interface des profils (permettant ainsi un meilleur affichage) et ne pourra plus servir de filtre ou pour constituer des sous-corpus, mais les annotations réalisées sont conservées dans la base de données et seront également exportées. Pour réactiver une catégorie, il suffit de cliquer sur le bouton [Unarchive](#).

Pour parcourir des catégories trop nombreuses dans l'interface **Edit category for accounts**, il est possible d'utiliser les touches du clavier "home" (début de page), "end" (fin de page), "page up" (monter de l'équivalent d'une page), "page down" (descendre de l'équivalent d'une page).

5. Annoter les publications

Cette section suit les mêmes principes que la précédente. Vous pouvez annoter les publications de deux façons :

- En écrivant dans l'espace d'annotation libre. Ces annotations se sauvegardent automatiquement, dès que vous cliquez en dehors de l'encadré d'annotation.
- En utilisant des catégories cliquables. Ces catégories peuvent avoir été créées lors de l'import (cfr. étapes 2.1), ou peuvent être créées dans SMIQQDA, dans l'interface **Edit category for posts**.

Pour créer des catégories dans l'interface **Edit category for posts**, entrez le nom de la catégorie et cliquez sur Add category. Vous pourrez ensuite créer des sous-catégories en cliquant sur Add sub-category. Catégories et sous-catégories sont classées par ordre alphabétique, et non par ordre d'entrée. Il est nécessaire de respecter les règles de nommage suivantes :

- Les majuscules et les chiffres sont acceptés. Nous conseillons de numérotter les catégories et sous-catégories (00, 01, etc.) si l'ordre d'entrée vous importe.
- Les signes diacritiques (apostrophes, cédilles, accents, etc) ne sont pas acceptés, ainsi que les espaces entre les mots (privilégiez des underscore).
- Certaines valeurs sont à éviter, notamment les nombres seuls ainsi que les valeurs génériques : « true/false » ; "vraie/faux" ; « oui/non » ; etc.

Pour créer des catégories lors de l'import, ajoutez le préfixe catPost_ suivi du nom de la colonne dans le fichier Excel des publications (les catégories des publications ne peuvent être importées que lors de l'import de publications). Nous vous conseillons de numérotter les catégories (après le symbole underscore) et d'éviter transformer en catégories des colonnes dont les cellules contiennent des valeurs uniques (bruit). Il est possible d'importer des annotations d'une catégorie déjà créée dans le display, il est alors impératif de respecter à l'identique le nom de la catégorie et des sous catégories. Veillez à ne pas laisser d'espace à la fin.

Pour supprimer une catégorie ou une sous-catégorie, cliquer sur Delete. Si une catégorie est supprimée, toutes ses variables et les annotations réalisées sont également supprimées. Lors de la suppression, une double confirmation est demandée pour éviter les fausses manipulations.

Pour archiver une catégorie ou une sous-catégorie, cliquez sur Archive. La (sous-)catégorie ne s'affichera plus dans l'interface des publications (permettant ainsi un meilleur affichage) et ne pourra plus servir de filtre ou pour constituer des sous-corpus, mais les annotations réalisées sont conservées dans la base de données et seront également exportées. Pour réactiver une catégorie, il suffit de cliquer sur le bouton [Unarchive](#).

Pour parcourir des catégories trop nombreuses dans l'interface **Edit category for posts**, il est possible d'utiliser les touches du clavier "home" (début de page), "end" (fin de page), "page up" (monter de l'équivalent d'une page), "page down" (descendre de l'équivalent d'une page).

6. Exporter des corpus de profils et de publications

Sur les interfaces Export account et Export post, il est respectivement possible d'exporter des corpus de profils et de publications. Il est possible d'exporter le corpus complet, ou d'exporter un sous-corpus partiel. Dans tous les cas, les fichiers d'exports sont entreposés dans le dossier **account** ou **post** (src \flaskr\export\excel). Lors de l'export, le fichier créé est sauvegardé sous un nom unique (à l'aide d'un timestamp), ce qui permet de ne pas écraser les fichiers d'export précédents et conserver une archive de qualité.

Pour exporter un corpus complet :

- **Export account** : sélectionnez « number of posts | greater or equal | 0 », puis appuyez sur SQL (ne cliquez qu'une seule fois et attendez que la requête soit terminée, cela peut prendre plus ou moins de temps selon la taille de votre corpus) puis sur OK.
- **Export post** : sélectionnez « post Id | not equal | 0 », puis appuyez sur SQL (ne cliquez qu'une seule fois et attendez que la requête soit terminée, cela peut prendre plus ou moins de temps selon la taille de votre corpus) puis sur OK.

Pour exporter un sous-corpus, il suffit de rédiger une requête SQL valide en sélectionnant vos critères, puis de cliquer sur SQL, puis sur OK. Les catégories constituent des critères de filtre (pour les publications, il est également possible d'utiliser les catégories des profils). Les requêtes SQL permettent également de rechercher directement à l'intérieur des textes (par exemple, vous pouvez sélectionner toutes les biographies contenant le mot « féministe »).

Les principes des requêtes SQL sont les suivants :

- « NOT » : si la case est cochée, les profils ou publications auxquelles s'applique la requête sont exclus du sous-corpus ;
- « AND » : les conditions sont supplémentaires (l'une et l'autre s'appliquent)
- « OR » : les conditions sont complémentaires (l'une ou l'autre s'appliquent)
- 1^{ère} case : choisir la nature du filtre
- 2^{ème} case : choisir la condition
- 3^{ème} case : définir la condition
- Add rule : ajouter des règles soumises aux mêmes opérateurs booléens (not, or, and)
- Add group : ajouter des règles qui ne sont pas nécessairement soumises aux mêmes opérateurs booléens (not, or, and)
- Account (sub)category : (sous-)catégories cliquables des profils comme filtres
- Post (sub)category : (sous-)catégories cliquables des publications comme filtres

Lors de la création de sous-corpus textuels de profils ou de publications (fichiers Excel), il est également possible de créer des sous-corpus structurés pour les images correspondantes. Il suffit alors de cocher la case Create sub-corpus with images avant d'appuyer sur le bouton SQL. Les sous-corpus d'images sont intitulés avec un timestamp unique, dans le dossier **img** (src\flaskr\export\img).

Lors de l'export de corpus complets et de sous-corpus), SMIQQA crée de nouvelles métadonnées afin d'enrichir les données :

- Pour les profils :
 - ✓ **imagesLocalPathAccount** [chemin des images, pour l'édition dans TXM]
 - ✓ **postsReallyCollected** [nombre de publications du compte réellement présents dans la base de données, sans les doublons]
 - ✓ **postsMissing** [nombre de posts non collectés (postsAsked - postsReallyCollected), utile pour évaluer la qualité de la collecte]
- Pour les publications :
 - ✓ **imagesReallyCollected** [nombre d'images de la publication que le script a réussi à collecter]
 - ✓ **imagesMissing** [numberImagesPost – imagesReallyCollected, utile pour évaluer la qualité de la collecte]

- ✓ `imagesLocalPath` [chemins des images, pour l'édition dans TXM]
- ✓ `date` [timestamp au format AAAA/MM/JJ, accepté par TXM]

Il est donc conseillé d'importer et d'exporter une première fois chaque corpus dans SMIQQDA avant de l'importer dans TXM.

Quant aux bonnes pratiques d'export, nous conseillons de :

- Ne cliquer qu'une seule fois sur le bouton SQL, pour en pas générer de bugs ;
- Attendre que la requête soit terminée (cela peut prendre plus ou moins de temps selon la taille de votre corpus et la complexité de votre requête). Il est possible de le savoir en observant l'invite de commande ou en vérifiant la création des fichiers d'export (Excel et sous-corpus d'images).

7. Sauvegarder, partager & restaurer la base de données

Lors de chaque import et export, SMIQQDA sauvegarde automatiquement la base de données à l'aide d'un nom unique (via un timestamp), selon le modèle `flasfr_timestamp.sqlite`. Ces différentes archives se trouvent dans le dossier `instance` (`src\instance`). Ces fichiers au format `.sqlite` permettent de partager facilement la base de données entre différentes chercheuses et de restaurer une version antérieure de la base de données en cas de fausses manipulations.

Pour restaurer une version antérieure de la base de données, il suffit de renommer cette version `flasfr.sqlite` (pensez à archiver/renommer la version précédente). Pour ce faire, il est impératif que SMIQQDA soit fermé, ainsi que l'invite de commande.

De temps en temps, il peut être utile de transférer les documents `.sqlite` sur une mémoire externe, car ils peuvent occuper beaucoup d'espace (selon la taille du corpus).

Fonctionnalités futures

SMIQQDA peut faire l'objet d'améliorations à différents niveaux. Le logiciel étant libre et ouvert, nous encourageons la communauté scientifique à y participer. Nous proposons quelques pistes :

- Intégrer une interface pour l'édition des OCR. Cette interface permettrait de comparer et de corriger directement les images et les résultats de l'OCR, pour améliorer la qualité des données.
- Intégrer davantage de formats multimodaux (par exemple audios et audiovisuels). Cela permettrait une analyse plus complète des plateformes de médias sociaux mentionnées, ainsi que l'étude d'autres plateformes ou types de corpus (par exemple, TikTok, Netflix, podcasts, etc.) ;
- Élargir les formats et possibilités d'import et d'export pour une meilleure articulation avec d'autres outils (`.png`, `.csv`, `.xml`, balises TEI pour les annotations automatisées dans Iramuteq, etc.) ;
- Développer des fonctionnalités d'annotation supplémentaires (par exemple, des balises, c'est-à-dire des annotations localisées sur des images) ;
- Améliorer le design pour le rendre plus esthétique et accessible (par exemple, créer des scripts bash pour automatiser la création de la base de données, le lancement de SMIQQDA et les imports des corpus) ;
- Élargir les possibilités de dénomination des images et faciliter ainsi l'articulation des données visuelles et textuelles ;
- Rendre facultatif l'import d'un corpus de profils comme préalable à l'import d'un corpus de publications ;

- Intégrer des messages d'erreurs précis et détaillés en français, en anglais et dans d'autres langues pour les utilisatrices non initiées à l'informatique ;
- Traduire la documentation et l'interface de SMIQQDA dans d'autres langues pour favoriser sa diffusion et son accessibilité.